实验三：KMeans&Spark分布式实践

Design by W.H Huang | Direct by Prof Feng

1 实验目的

通过本次实验，你应该：

- 熟悉基于`Spark`分布式编程环境
- 掌握`HDFS`分布式文件系统基本操作
- 掌握`KMeans`聚类算法以及了解`matplotlib`可视化工具

本次实验你将使用鸢尾花`Iris`数据集完成本次`KMenas`聚类实验，将相同亚种类型的鸢尾花聚类为一个簇。

相关数据集来源于：[iris数据集官网下载]

`Iris`数据的样本容量为`150`，有四个实数值的特征，分别代表花朵四个部位的尺寸。最后字符串为该样本对应鸢尾花的亚种类型。如下图所示：

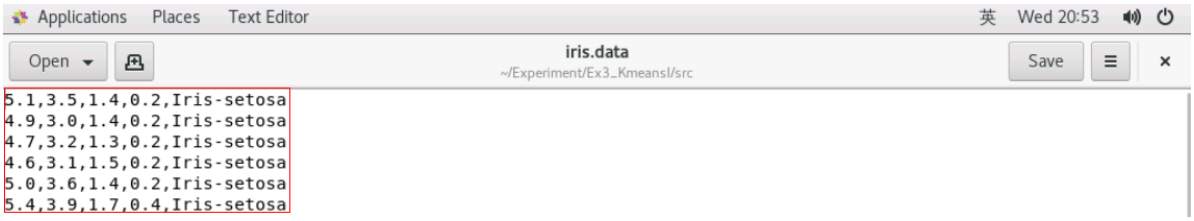

`实验二`中已将所有实验上传到服务器，`Iris`数据集在`/usr/local/Experiment/Ex3_KmeansI/src/iris.data`下，你现在可以在服务器上进行查看。

1.1 `Kmeans`算法

算法流程

假设输入样本集$D=x_1,x_2,\ldots,x_m$，聚类簇数为K，最大迭代次数为N。输出的簇划分为$C=C_1,C_2,\ldots,C_m$。

- 从数据集D中随机选择K个样本作为初始的质心向量$\mu=\{\mu_1,\mu_2,\mu_3,\ldots,\mu_k\}$。
- 迭代$n=1,2,\ldots,N$。
  - 划分初始化簇$C_t=\varnothing;\ t=1,2,\ldots,k$。
  - 对于$i=1,2,\ldots,m$，计算样本x_i和各个质心向量$\mu_j(\ j=1,2,\ldots,k)$的距离d_{ij}。将x_i标记为最小的d_{ij}所对应的类别λ_i，此时更新$C_{\lambda i}=C_{\lambda i}\cup x_i$。

$$d_{ij}=||x_i-\mu_j||^2$$

  - 对于$j=1,2,\ldots,k$，对C_j中所有样本点重新计算新的质心。

$$\mu_j=\frac{1}{|C_j|}\sum_{x\in C_j}x$$

  - 如果K个质心向量都不再发生变化，则结束迭代。
- 输出K个划分簇C，$C=\{C_1,C_2,C_3,\ldots,C_k\}$。

对于K-Means算法，首先要注意K值的选择和K个初始化质心的选择。

- **K值选择**：通过计算不同`K`对应损失，选择第一次拐角处`k`作为最佳聚类簇数，详见下
- **质心选择**：本次实验不讨论

相关API

> 官方`API`文档：[org.apache.spark.ml.clustering]

现在你需要根据相关提示完成`iris.py`与`kmeans.py`两个`py`文件相关函数编写。

2 实验准备

2.1 安装相关模块

> ⚠ 本次实验运行在分布式集群下，以下相关模块需要在`master`和`slave`都进行安装。

- 安装`matplotlib`

```
sudo pip3 install matplotlib -i https://pypi.tuna.tsinghua.edu.cn/simple
```

2.2 上传`hdfs`

> ☺ `hdfs`常用相关操作可参考：[hdfs常用操作]

`hdfs`是一个分布式文件系统，现在你将需要在正式实验前将相关数据集上传`hdfs`文件系统上。

1. 创建文件夹

```
cd /usr/local/hadoop
./bin/hadoop fs -mkdir -p /ex3/dataset  # -p 参数可用于创建多级目录
```

```
./bin/hadoop fs -ls -R /  # 查看是否创建成功
```

```
[hadoop@master hadoop]$ ./bin/hadoop fs -ls -R /
drwxr-xr-x   - hadoop supergroup          0 2020-01-28 11:58 /ex
drwxr-xr-x   - hadoop supergroup          0 2020-01-28 13:31 /ex/ex3dataset
```

2. 上传数据集

> 如果云服务器上传失败，通常是因为云服务安全组禁止了相关端口开放：
>
> - 参考1：[issue#12]
> - 参考2：[issue#7 @yacaikk] 重新配置安全组端口开放即可

将本地文件`iris.data`上传到`hdfs://master:9000/ex/ex3dataset/iris.datat`。

📝 以下上传的`hdfs`路径可简写为：`/ex/ex3dataset`

```
./bin/hadoop fs -put /home/hadoop/Experiment/Ex3_KmeansI/src/iris.data
/ex/ex3dataset
```

查看是否上传成功：

```
./bin/hadoop fs -ls -R /
```

```
[hadoop@master hadoop]$ ./bin/hadoop fs -ls -R /
drwxr-xr-x   - hadoop supergroup          0 2020-01-28 11:58 /ex
drwxr-xr-x   - hadoop supergroup          0 2020-01-28 13:31 /ex/ex3dataset
-rw-r--r--   3 hadoop supergroup       4551 2020-01-28 13:31 /ex/ex3dataset/iris.data
```

3 完成编码

在实验开始之前，我们强烈建议你按照以下流程完成实验：

1. **命令行** 下完成代码 **单元测试**
2. 单元测试无误，将代码填充在相应给出的`py`文件函数中
3. `spark-submit`方式提交代码

> ☺ 如何在命令行下完成单元测试?

1. 启动`pyspark`

   ⚠本次实验都是在集群环境下，集群启动`pyspark`应该按以下方式：

   - 先启动`Hadoop/Spark`集群

     ```
     # 启动hadoop集群
     cd /usr/local/hadoop
     sbin/start-all.sh
     # 启动spark集群
     cd /usr/local/spark
     sbin/start-master.sh
     sbin/start-slaves.sh
     ```

   - 启动`pyspark`

     ```
     bin/pyspark --master spark://master:7077
     ```

2. 命令行下单元测试

   通过命令行下实时`交互式体验`，来快速测试代码是否正确。

   具体实例可参考`ex2`中示例。

3. 提交代码

   在命令行下单元测试后，便可以填写在相应`py`文件中。

   本次实验通过`spark-submit`方式提交代码至 **集群** ，请参照实验 **3.3.1** 部分进行。

3.1 `iris.py`

`iris.py`可在服务器路径`/home/hadoop/Experiment/Ex3_KmeansI/iris.py`编辑：

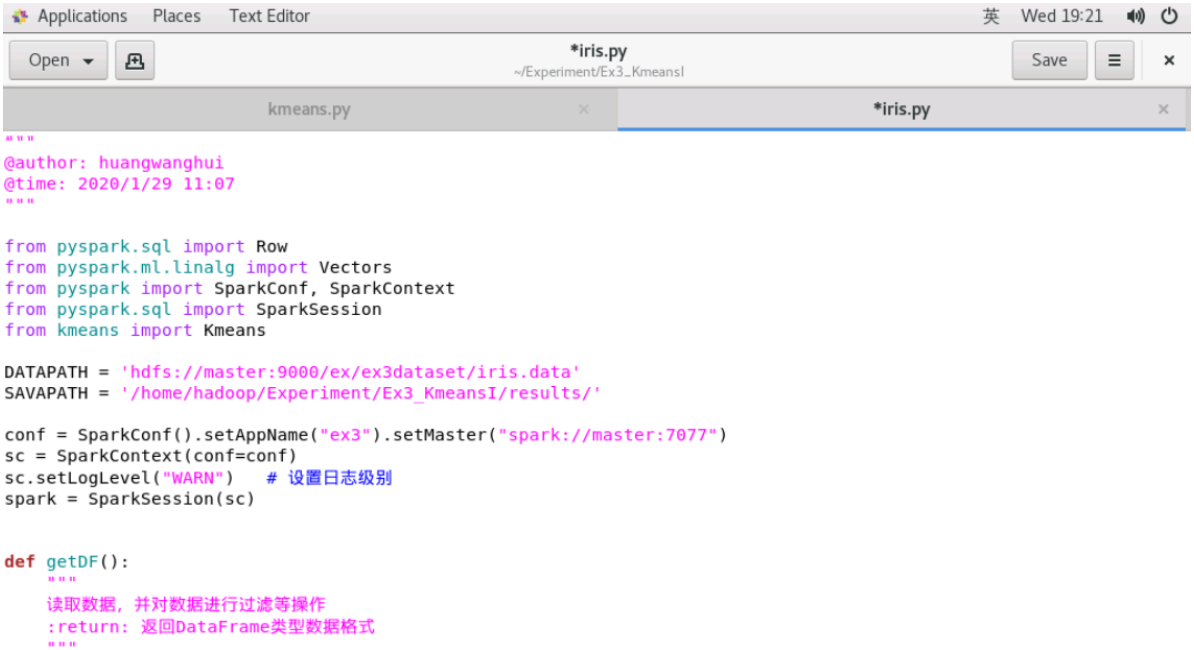

相关函数及功能如下：

- `getDF`： 读取数据，并对数据进行过滤等操作
- `f`： 将`RDD`类型每一行转换为`Dense Vector`类型
- `main`：串联整个流程

现在请根据提示，完成相应函数：

```
from pyspark.sql import Row
from pyspark.ml.linalg import Vectors
from pyspark import SparkConf, SparkContext
from pyspark.sql import SparkSession
from kmeans import Kmeans

DATAPATH = 'hdfs://master:9000/ex/ex3dataset/iris.data'
SAVAPATH = '/home/hadoop/Experiment/Ex3_KmeansI/results/'

# 命令行下以下不用设置，已存在相应实例
conf = SparkConf().setAppName("ex3").setMaster("spark://master:7077")
sc = SparkContext(conf=conf)
sc.setLogLevel("WARN")  # 设置日志级别
spark = SparkSession(sc)


def getDF():
    """
    读取数据，并对数据进行过滤等操作
    :return: 返回DataFrame类型数据格式
    """

    # 读取数据
    # 利用filter操作过滤掉空数据,如：[['1'],['2'],['']] --> [['1'],['2']]
    # 现在你需要【完成以下编码】
    # rawData = sc.textFile(DATAPATH).filter(lambda ele: ele != '')
    rawData = sc.textFile(DATAPATH).filter(lambda ele: )

    # 转换为DataFrame
    # 你应该依次利用SparkRDD操作完成：
    # 1.map 将RDD每一行数据以逗号‘，’分隔
```

```
    # 2.map RDD每一行转换为Row

    dataDF = rawData.map(lambda line: )\
                    .map(lambda p: )\
                    .toDF()
    return dataDF

def f(x):
    """
    将x转换为Vector
    :param x: 对应iris.data（RDD）每一行
    :return:
    """
    rel = {}
    rel['features'] = Vectors.dense(float(x[0]), float(x[1]), float(x[2]),
float(x[3]))
    return rel


def main():
    # 1.读取数据
    dataDF = getDF()

    # 2.测试最佳K值，第一次出现明显拐角处便是最佳K值
    km = Kmeans()
    km.searchK(SAVAPATH,dataDF,2,12)    # 查看保存的图片，选择最佳K值

    # 3.打印聚类结果
    km.printResults(dataDF,best_k=3)


if __name__ == "__main__":

    # run code
    main()
```

3.2 kmeans.py

`kmeans.py` 相关函数及功能如下：

- `searchK`：计算不同K值对应损失，从而寻找出最佳`K`值
- `printResults`： 打印最终`KMeans`聚类结果

现在请根据提示，完成相应函数：

```
from pyspark.ml.clustering import KMeans
import matplotlib.pyplot as plt

class Kmeans:

    def searchK(self, SAVAPATH, dataDF, k_min, k_max):
        """
        寻找最佳K值
        :param SAVAPATH: 保存结果路径
        :param dataDF: DataFrame类型数据
        :param k_min: 最小k值
        :param k_max: 最大k值
```

```
        :return:
        """

        # 计算不同k值对应损失
        k_range = range(k_min,k_max)  # 指定k寻找范围
        costs = []
        # 利用pyspark.ml.clustering.Kmeans类函数计算损失
        # 1.定义KmeansModel，对DataFrame类型数据进行整体化处理，生成带预测簇标签的数据集
        # 2.计算损失
        for k in k_range:
            kmeansModel = KMeans()\
                          .setK(k)\
                          .setFeaturesCol('features')\
                          .setPredictionCol('prediction')\
                          .fit(dataDF)
            # 【完成以下编码】计算损失
            costk =
            costs.append(costk)

        # 可视化损失结果
        fig, ax = plt.subplots(1, 1, figsize=(8, 6))
        ax.plot(k_range, costs)
        ax.set_xlabel('k')
        ax.set_ylabel('cost')
        # 保存k-cost结果
        plt.savefig(SAVAPATH + 'k_cost.png')

    def printResults(self, dataDF, best_k,end=50):
        """
        打印聚类结果
        :param dataDF: DataFrame类型数据
        :param best_k: 指定最佳K值
        :param end: 打印多少行
        :return:
        """
        kmeansModel = KMeans() \
                      .setK(best_k) \
                      .setFeaturesCol('features') \
                      .setPredictionCol('prediction') \
                      .fit(dataDF)
        # 获取聚类预测结果
        # 1.利用pyspark.ml.clustering.KMeans中transform方法得到聚类结果
        # 2.利用DataFrame中collect方法转换DateFrame --> python list
        # 【现在完成以下编码】

        resDF =
        resList =
        # 打印部分聚类结果
        for item in resList[:end]:
            print(str(item[0]) + ' is predcted as cluster' + str(item[1]))
```

3.3 集群运行

3.3.1 集群运行任务

按照以下步骤启动集群运行任务：

1. 启动集群

   > ⚠ 启动集群下`pyspark`已启动集群则略过这步。

   启动`hadoop`集群

   ```
   cd /usr/local/hadoop
   sbin/start-all.sh
   ```

   启动`spark`集群

   ```
   cd /usr/local/spark
   sbin/start-master.sh
   sbin/start-slaves.sh
   ```

2. 上传集群运行任务

   提交代码：

   ```
   cd /usr/local/spark
   bin/spark-submit --master spark://master:7077 --py-files
   /home/hadoop/Experiment/Ex3_KmeansI/kmeans.py --executor-memory 1G
   /home/hadoop/Experiment/Ex3_KmeansI/iris.py
   ```

   相关参数及意义：

   > 更多可参考博客：[spark-submit参数]

   - `--master`：设置集群的主URL，用于决定任务提交到何处执行。常见选项：
     - `local`:提交到本地服务器执行，并分配单个线程
     - `local[k]`:提交到本地服务器执行，并分配`k`个线程
     - `spark://MASTERHOST:PORT`:提交到`standalone`模式部署的`spark`集群中
   - `--class CLASS_NAME`:指定应用程序的类入口，即主类，仅针对`java、scala`程序，不作用于python程序
   - `--name NAME`:应用程序的名称
   - `--py-files PY_FILES`:逗号隔开的的`.zip、.egg、.py`文件，这些文件会放置在`PYTHONPATH`下，该参数仅针对`python`应用程序
   - `--executor-memory MEM`:每个`executor`的内存，默认是`1G`

3. 运行过程

   一切正常，你将会看到运行过程中打印出聚类结果：

```
20/01/29 17:31:44 WARN BLAS: Failed to load implementation from: com.github.fomm
il.netlib.NativeRefBLAS
[5.1,3.5,1.4,0.2] is predcted as cluster1
[4.9,3.0,1.4,0.2] is predcted as cluster1
[4.7,3.2,1.3,0.2] is predcted as cluster1
[4.6,3.1,1.5,0.2] is predcted as cluster1
[5.0,3.6,1.4,0.2] is predcted as cluster1
[5.4,3.9,1.7,0.4] is predcted as cluster1
[4.6,3.4,1.4,0.3] is predcted as cluster1
[5.0,3.4,1.5,0.2] is predcted as cluster1
```

4. `Web UI` 查看

   `Master` 服务器输入：*master:8080* , 可查看此前运行的应用进程信息：

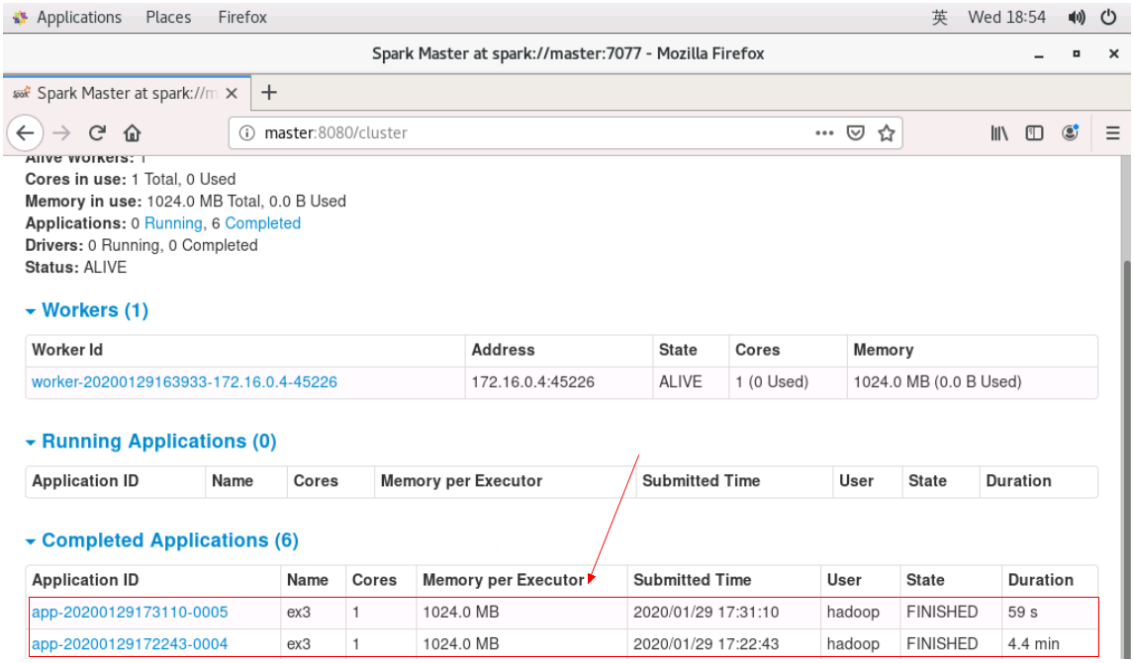

3.3.2 结果分析

寻找最佳 k 值

查看 `/home/hadoop/Experiment/Ex3_KmeansI/results/k_cost.png` 结果如下：

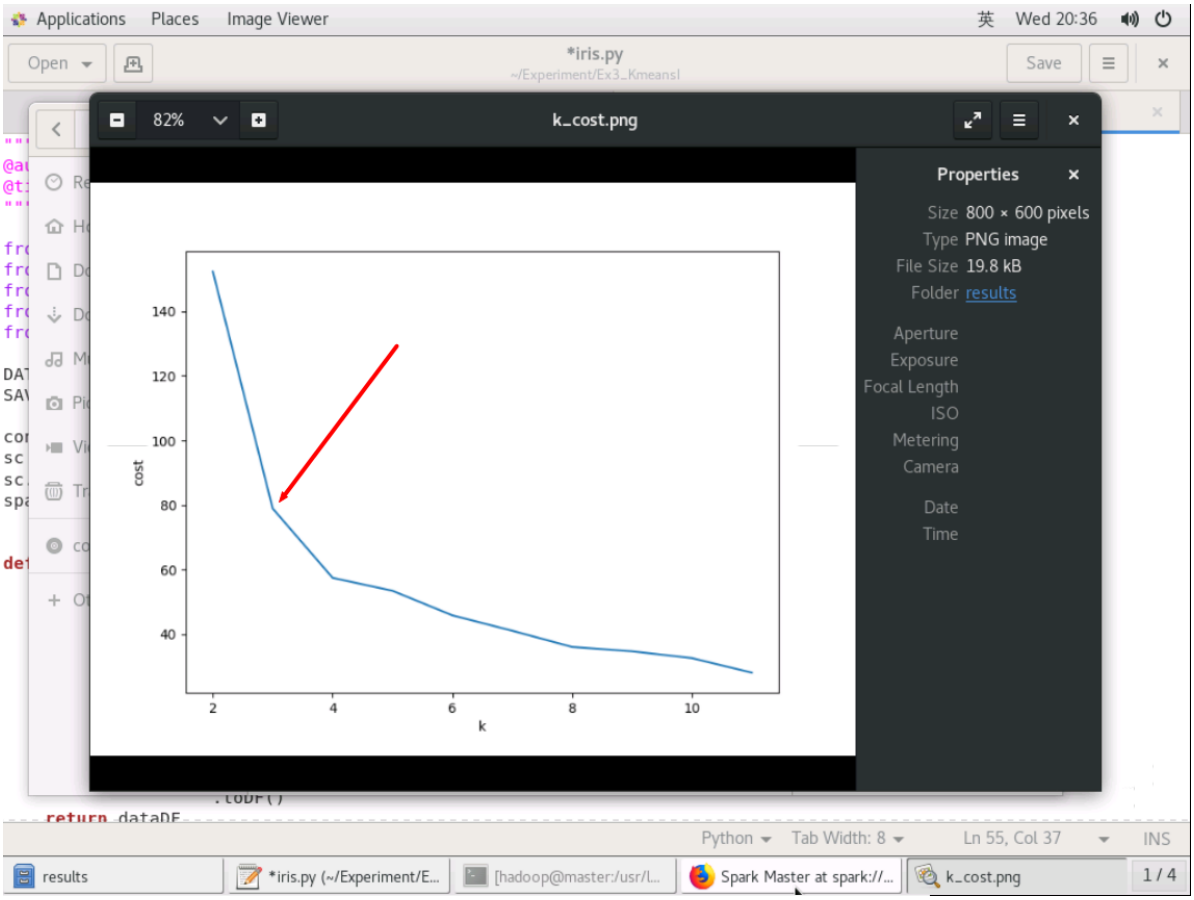

可以看到`KMeans`算法在聚类时`K=3`处发生第一次明显拐角：`K=3`之前快速下降，`K=3`之后下降缓慢。因此我们选择`K=3`为最佳分类簇数。此时损失约为`78`。

实际上我们给出的数据集中鸢尾花亚种类型便只有**3**种，可见我们的分析是准确的。

3.4 常见集群错误

> 集群报错：`An error occurred while trying to connect to the Java sever(127.0.0.1:42523)`

```
ERROR:py4j.java_gateway:An error occurred while trying to connect to the Java server (127.0.0.1:42523)
Traceback (most recent call last):
  File "/usr/local/spark/python/lib/py4j-0.10.7-src.zip/py4j/java_gateway.py", line 929, in _get_connec
tion
    connection = self.deque.pop()
IndexError: pop from an empty deque

During handling of the above exception, another exception occurred:
```

> 没有什么是重启不能解决的，如果有那就_____?

这个情况原因暂时不明，有可能突然出现。初步猜测是端口占用问题。

尝试以下方法一般都能解决：

1. 关闭集群

   关闭`spark`集群

   ```
   cd /usr/local/spark/
   sbin/stop-all.sh
   ```

   关闭`hadoop`集群

   ```
   cd /usr/local/hadoop/
   sbin/stop-all.sh
   ```

2. 启动集群

   启动 `hadoop` 集群

   ```
   cd /usr/local/hadoop
   sbin/start-all.sh
   ```

   启动 `spark` 集群

   ```
   cd /usr/local/spark
   sbin/start-master.sh
   sbin/start-slaves.sh
   ```

再次执行任务如果错误还不能解决，可尝试 `关机重启Master服务器` --> `再执行上述1、2步骤`

4 实验小结

通过本次实验，你初步了解了在 `Spark` 分布式编程环境也独立完成了一个简单 `KMeans` 聚类，相信聪明的你也一定不少困难。不过，完全不用气馁，刚接触 `Spark` 分布式遇到的问题也常让我苦恼很久，全靠 `Google` 、百度、 `Stackoverflow` 才有勇气面对自己是个 `zz` 的事实，你们也应该好好掌握上面几个工具 `Debug` 。

接下来，你将面对本门课程最后一次实验，它比以前实验相对而言更具有一点挑战性但是并不复杂，更多的介绍就留在下次实验详细和你说吧。